

UNIVERSIDADE FEDERAL DE ALAGOAS

CAMPUS ARAPIRACA

UNIDADE EDUCACIONAL PENEDO

CURSO DE BACHARELADO EM SISTEMAS DE INFORMAÇÃO

6º PERÍODO

JOSÉ GABRIEL FIDELES SILVA

CIÊNCIA DOS DADOS E INTELIGÊNCIA EMPRESARIAL

ATIVIDADE PRÁTICA

Penedo - AL

2026

JOSÉ GABRIEL FIDELES SILVA

CIÊNCIA DOS DADOS E INTELIGÊNCIA EMPRESARIAL

ATIVIDADE PRÁTICA

Trabalho solicitado na disciplina de Ciência dos Dados e Inteligência Empresarial, do Curso Bacharelado em Sistemas de Informação da Universidade Federal de Alagoas, *Campus* Arapiraca - Unidade Educacional Penedo como requisito para obtenção parcial de nota da AB1.

Orientado pelo docente Jário José.

Penedo - AL

2026

SUMÁRIO

RESUMO....4
1. Introdução e Contexto....6
1.1 Motivação....6
1.2 Base de dados....6
1.3 Objetivo geral e perguntas de negócio....6
2. Metodologia....8
2.1 Ferramentas....8
2.2 Etapas do tratamento dos dados....8
2.3 Tipagem das variáveis....9
2.4 Procedimentos estatísticos....9
3. Análise Descritiva e Exploratória....11
3.1 Variáveis numéricas....11
3.2 Variáveis categóricas....12
3.3 Rotatividade por departamento e cargo (Q1)....13
3.4 Renda e rotatividade (Q2)....13
3.5 Envolvimento e ambiente de trabalho (Q3)....14
3.6 Hora extra (Q4)....15
3.7 Desempenho, envolvimento e reajuste (Q5)....16
3.8 Correlações e perfil de risco....16
4. Análise Inferencial....19
4.1 Q1: Taxa de rotatividade e departamento....19
4.2 Q2: Renda de quem sai × quem fica....19
4.3 Q3: Envolvimento, ambiente, satisfação e vida-trabalho....19
4.4 Q4: Hora extra....20
4.5 Q5: Desempenho, envolvimento e reajuste....20
4.6 Síntese dos resultados inferenciais....21
5. Recomendações Práticas....23
5.1 Plano de ação....23
5.2 Limitações e próximos passos....24
6. Referências e Apêndices....25
6.1 Referências....25
6.2 Código-fonte e reprodutibilidade....25
Apêndice A – Verificação dos pressupostos....25
Apêndice B – Dicionário de dados resumido....26

RESUMO

Este relatório investiga os fatores associados à rotatividade voluntária de funcionários a partir da base IBM HR Analytics (1.470 funcionários, 35 variáveis). O objetivo é apoiar a área de Gestão de Pessoas na priorização de ações de retenção com base em evidências estatísticas. Após o diagnóstico de qualidade e a limpeza dos dados, foram aplicadas estatística descritiva e cinco procedimentos inferenciais (intervalo de confiança, teste t, ANOVA, qui-quadrado e teste de correlação, com $\alpha = 0,05$). A taxa de rotatividade é de **16,1%** (IC 95%: 14,3% a 18,1%). O **principal achado** é que funcionários que fazem hora extra saem **2,9 vezes mais** (30,5% contra 10,4%; $p < 0,001$). Baixo envolvimento com o trabalho (33,7% de saída), baixa satisfação com o ambiente, equilíbrio vida-trabalho ruim e cargos de entrada, de menor renda, também estão associados à saída. Já o reajuste salarial depende apenas da nota de desempenho, que não diferencia quem sai de quem fica. A **principal recomendação** é implantar a gestão ativa de horas extras, combinada a um programa de retenção para cargos de entrada e a um sistema de alerta baseado em pesquisas de clima.

Tabela 1 – Indicadores-chave do estudo

Rotatividade	Hora extra	Envolvimento	Renda
16,1%	2,9×	33,7%	29,3%
taxa de rotatividade	risco de saída com hora extra	saída com envolvimento baixo	saída no quartil de menor renda

Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

Palavras-chave: Rotatividade de pessoal; People Analytics; Teste de hipóteses; Inteligência empresarial; Gestão de pessoas.

ABSTRACT

This report investigates the factors associated with voluntary employee attrition using the IBM HR Analytics dataset (1,470 employees, 35 variables), aiming to support People Management in prioritizing evidence-based retention actions. After data quality assessment and cleaning, descriptive statistics and five inferential procedures were applied (confidence interval, t-test, ANOVA, chi-square and correlation test, $\alpha = 0.05$). The attrition rate is 16.1% (95% CI: 14.3% to 18.1%). The main finding is that employees who work overtime leave 2.9 times more often (30.5% vs. 10.4%; $p < 0.001$). Low job involvement, low environment satisfaction, poor work-life balance and lower-paid entry-level roles are also associated with attrition, while salary raises depend only on the performance rating, which does not distinguish leavers from stayers. The main recommendation is active overtime management, combined with a retention program for entry-level roles and an early-warning system based on engagement surveys.

Keywords: Employee attrition; People Analytics; Hypothesis testing; Business intelligence; Human resources.

1. Introdução e Contexto

1.1 Motivação

A rotatividade voluntária de funcionários (*attrition*) é um dos indicadores mais acompanhados pela área de Gestão de Pessoas. Cada desligamento gera custos diretos (recrutamento, seleção, integração e treinamento do substituto) e indiretos (perda de conhecimento, queda de produtividade e sobrecarga da equipe). Entender **quais fatores estão associados à saída** permite que a empresa atue de forma preventiva e direcione recursos para os grupos de maior risco, em vez de aplicar ações genéricas a todo o quadro.

Este trabalho aplica o ciclo de Inteligência Empresarial (coleta, tratamento, análise descritiva, inferência estatística e recomendação) a uma base de Recursos Humanos, com foco em três dimensões controláveis pela gestão: **remuneração**, **envolvimento com o trabalho** e **ambiente de trabalho**.

1.2 Base de dados

Foi utilizada a base **IBM HR Analytics Employee Attrition & Performance**, publicada no Kaggle (https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset/data). Ela contém **1.470 registros** (um por funcionário) e **35 variáveis**: demográficas (idade, gênero, estado civil), de carreira (cargo, nível, tempo de empresa, promoções), de remuneração (renda mensal, reajuste, ações) e de percepção (satisfação com o ambiente, com o trabalho, envolvimento e equilíbrio vida-trabalho, em escalas de 1 a 4). A variável-alvo é **Attrition** (saiu: sim/não), com 237 saídas registradas.

A base atende aos requisitos da atividade (mínimo de 500 registros, 5 variáveis numéricas e 3 categóricas). **Importante:** os dados são **fictícios**, criados por cientistas de dados da IBM para fins didáticos. As conclusões ilustram o método analítico e não descrevem uma empresa real.

1.3 Objetivo geral e perguntas de negócio

Objetivo geral: identificar os fatores salariais, de envolvimento e de ambiente de trabalho associados à rotatividade de funcionários, para subsidiar ações de retenção priorizadas por evidência estatística. Para isso, foram formuladas cinco perguntas de negócio (Tabela 2).

Tabela 2 – Perguntas de negócio e procedimentos associados

Nº	Pergunta de negócio	Procedimento inferencial
Q1	Qual é a taxa de rotatividade e ela difere entre departamentos?	IC 95% da proporção; Qui-Quadrado
Q2	Funcionários que saem ganham menos do que os que ficam?	Teste t; IC 95% da diferença de médias
Q3	Envolvimento, ambiente, satisfação e equilíbrio vida-trabalho estão associados à saída?	Qui-Quadrado (×4) com correção de Holm
Q4	Fazer hora extra está associado a mais saídas?	Qui-Quadrado 2×2; IC 95% da diferença de proporções
Q5	O desempenho e o envolvimento se refletem no reajuste salarial?	Teste t; ANOVA; Teste de correlação

Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

2. Metodologia

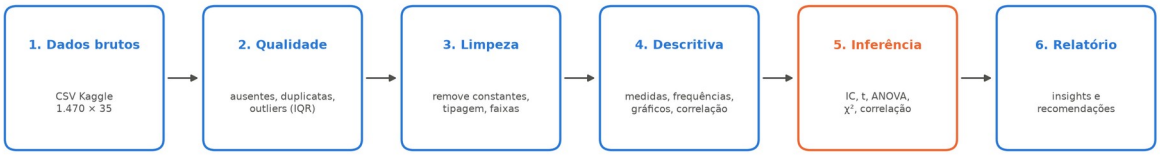
2.1 Ferramentas

A análise foi desenvolvida em **Python 3.14**, com as bibliotecas **pandas** e **NumPy** (manipulação de dados), **SciPy** e **statsmodels** (testes estatísticos e intervalos de confiança), **Matplotlib** e **seaborn** (visualização) e **Jupyter Notebook** (documentação do passo a passo). O código está organizado em três notebooks (limpeza, descritiva e inferencial) e em módulos reutilizáveis na pasta *src/*. O script *run_all.py* reproduz toda a análise e este relatório a partir do arquivo original. O repositório está em https://github.com/josefideles/sisb110-ibm-hr-analytics.

2.2 Etapas do tratamento dos dados

O fluxo de trabalho seguiu as etapas do roteiro da atividade (Figura 1).

Figura 1 – Fluxo metodológico da análise



Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

O diagnóstico de qualidade não encontrou **valores ausentes** nem **registros duplicados**. Três colunas constantes foram removidas e três colunas de "taxa" foram excluídas da análise por inconsistência com a renda mensal (correlação próxima de zero). Os **outliers** foram identificados pela regra do intervalo interquartil (valores fora de Q1 − 1,5·IQR e Q3 + 1,5·IQR) e **mantidos**, por representarem situações legítimas, como salários de diretores e funcionários com muitos anos de casa (Figura 2). O efeito deles foi controlado na etapa inferencial. A Tabela 3 resume as decisões.

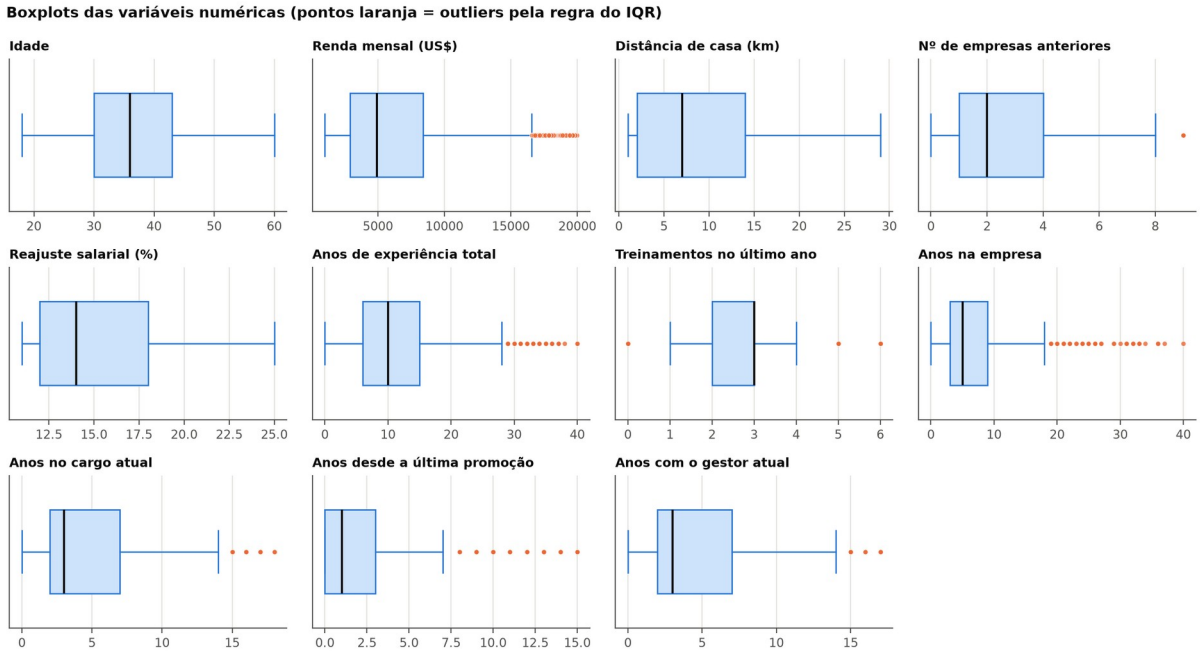
Tabela 3 – Decisões de limpeza e qualidade dos dados

Verificação	Resultado	Ação	Justificativa
Valores ausentes	0 em 35 colunas	Nenhuma ação	Base completa
Duplicatas	0 linhas · 0 IDs	Nenhuma ação	Cada linha é um funcionário único
Colunas constantes	EmployeeCount, Over18, StandardHours	Removidas	Variância zero, sem informação
Identificador	EmployeeNumber	Mantido só como ID	Não é variável analítica
Taxas inconsistentes	DailyRate, HourlyRate, MonthlyRate	Mantidas, fora da análise	Correlação ≈ 0 com MonthlyIncome
Outliers (IQR)	713 valores em 8 variáveis	Mantidos	Valores legítimos (cargos sêniores); testes robustos na Etapa III
Escalas 1–4 / 1–5	Satisfação, envolvimento, escolaridade...	Convertidas em ordinais rotuladas	São categorias ordenadas, não medidas

Verificação	Resultado	Ação	Justificativa
Variáveis derivadas	Attrition_bin, OverTime_bin, faixas	Criadas	Facilitar taxas e leitura de negócio

Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

Figura 2 – Boxplots das variáveis numéricas e outliers pela regra do IQR



Pontos laranja: valores fora dos limites do IQR. Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

2.3 Tipagem das variáveis

Cada variável foi classificada pelo seu tipo estatístico, que define as medidas e testes adequados. As escalas de 1 a 4 (satisfação, envolvimento) foram tratadas como **qualitativas ordinais**, e não como medidas contínuas (Tabela 4).

Tabela 4 – Tipagem estatística das variáveis analisadas

Tipo estatístico	Variáveis
Quantitativa contínua	Idade; Renda mensal
Quantitativa discreta	Distância de casa; Nº de empresas anteriores; Reajuste salarial; Anos de experiência total; Treinamentos no último ano; Anos na empresa; Anos no cargo atual; Anos desde a última promoção; Anos com o gestor atual
Qualitativa nominal	Rotatividade; Departamento; Cargo; Área de formação; Gênero; Estado civil; Hora extra
Qualitativa ordinal	Viagens a trabalho; Escolaridade; Satisfação com o ambiente; Envolvimento com o trabalho; Nível do cargo; Satisfação com o trabalho; Avaliação de desempenho; Satisfação com relacionamentos; Nível de ações; Equilíbrio vida-trabalho

Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

2.4 Procedimentos estatísticos

Na etapa descritiva foram calculadas média, mediana, desvio padrão, intervalo interquartil (IQR), assimetria, mínimo e máximo das variáveis numéricas, e frequências absolutas e relativas das categóricas. A matriz de correlação usou o coeficiente de **Spearman**, adequado a variáveis assimétricas e ordinais.

Na etapa inferencial, todos os testes adotaram **nível de significância α = 0,05** e seguiram o mesmo roteiro: hipóteses H_0 e H_1, verificação de pressupostos, escolha justificada do teste, estatística, p-valor, decisão, tamanho de efeito e interpretação de negócio. Os procedimentos foram:

- **Intervalos de confiança (95%)** para proporções pelo método de **Wilson** e para a diferença de proporções pelo método de **Newcombe**, ambos mais precisos que o método clássico para proporções distantes de 50% ou grupos pequenos;
- **Teste t de Student** para duas médias, na versão de **Welch** quando o teste de Levene indicou variâncias diferentes. A normalidade foi avaliada por Shapiro-Wilk e gráficos Q-Q. Com amostras grandes (n > 30), o Teorema Central do Limite sustenta a inferência sobre médias;
- **ANOVA** de um fator para três ou mais médias, com teste de Levene e post-hoc de Tukey quando necessário;
- **Teste Qui-Quadrado** de independência para pares de variáveis categóricas, verificando frequências esperadas ≥ 5, com **correção de Holm** para o conjunto de quatro testes da Q3;
- **Teste de correlação** (Pearson e Spearman) para relações entre variáveis quantitativas.

Os tamanhos de efeito (V de Cramér, d de Cohen, η^2 e r) foram interpretados segundo Cohen (1988), para distinguir diferenças **estatisticamente significativas** de diferenças **relevantes na prática**.

3. Análise Descritiva e Exploratória

3.1 Variáveis numéricas

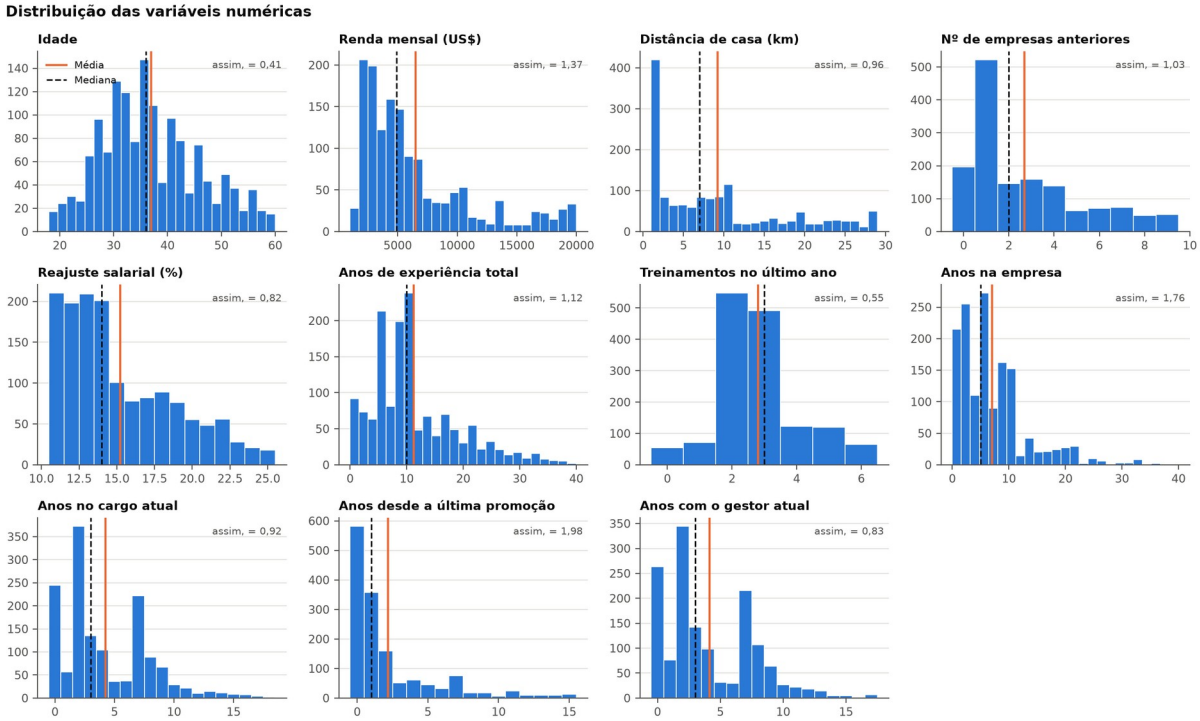
A Tabela 5 apresenta as medidas-resumo. A **idade** é praticamente simétrica (média de 36,9 e mediana de 36 anos). A **renda mensal** tem forte assimetria à direita (assimetria = 1,37): a média (US$ 6.503) supera bastante a mediana (US$ 4.919), por isso a mediana representa melhor o salário típico. As variáveis de tempo (anos na empresa, desde a última promoção) também são assimétricas: a maioria dos funcionários tem pouco tempo de casa, e poucos têm décadas (Figura 3).

Tabela 5 – Medidas descritivas das variáveis numéricas (n = 1.470)

Variável	Média	Mediana	DP	IQR	Assim.	Mín.	Máx.
Idade	36,9	36,0	9,1	13,0	0,41	18	60
Renda mensal (US$)	6.502,9	4.919,0	4.708,0	5.468,0	1,37	1.009	19.999
Distância de casa (km)	9,2	7,0	8,1	12,0	0,96	1	29
Nº de empresas anteriores	2,7	2,0	2,5	3,0	1,03	0	9
Reajuste salarial (%)	15,2	14,0	3,7	6,0	0,82	11	25
Anos de experiência total	11,3	10,0	7,8	9,0	1,12	0	40
Treinamentos no último ano	2,8	3,0	1,3	1,0	0,55	0	6
Anos na empresa	7,0	5,0	6,1	6,0	1,76	0	40
Anos no cargo atual	4,2	3,0	3,6	5,0	0,92	0	18
Anos desde a última promoção	2,2	1,0	3,2	3,0	1,98	0	15
Anos com o gestor atual	4,1	3,0	3,6	5,0	0,83	0	17

DP = desvio padrão; IQR = intervalo interquartil; Assim. = coeficiente de assimetria. Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

Figura 3 – Distribuição das variáveis numéricas

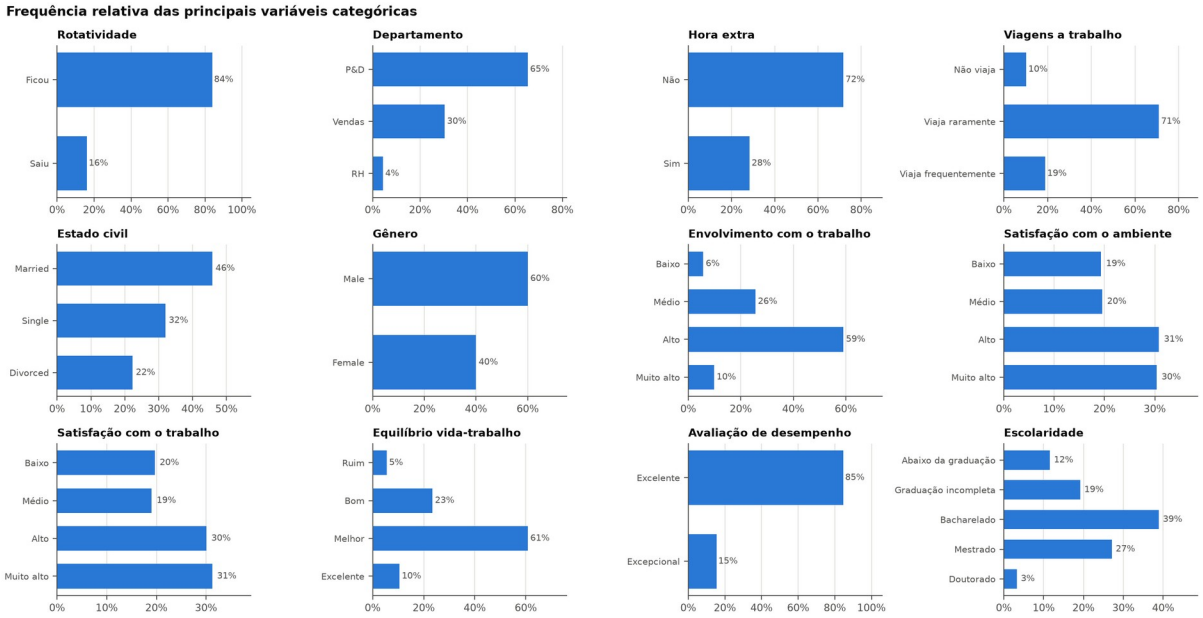


Linha laranja: média; linha preta tracejada: mediana. Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

3.2 Variáveis categóricas

A variável-alvo é desbalanceada: **16,1% dos funcionários saíram**. P&D concentra 65,4% do quadro, Vendas 30,3% e RH apenas 4,3%. Fazem hora extra 28,3% dos funcionários. Um ponto de atenção é a **avaliação de desempenho**: só existem as notas 3 (84,6%) e 4 (15,4%), e nenhuma nota 1 ou 2, o que sugere **inflação de avaliações** (Figura 4).

Figura 4 – Frequência relativa das principais variáveis categóricas

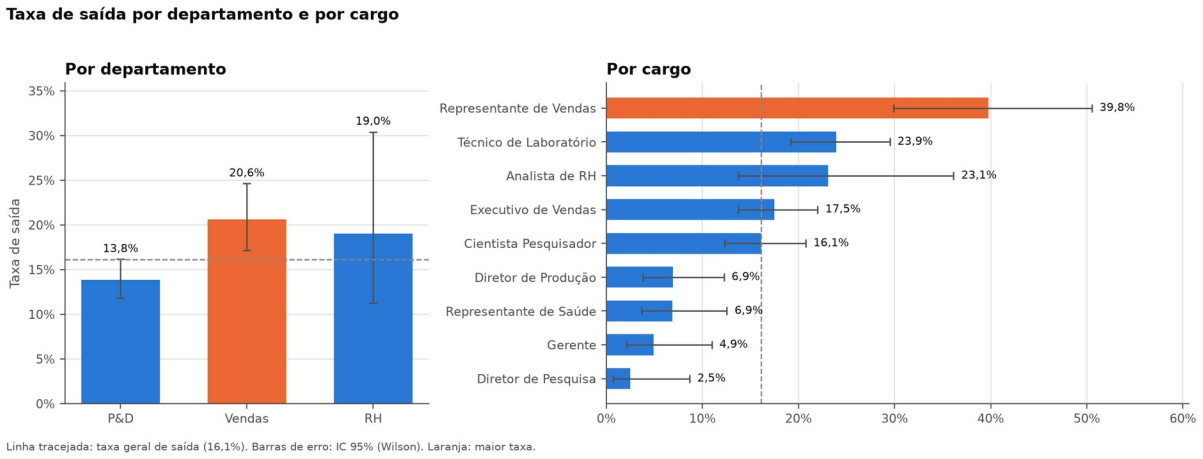


Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

3.3 Rotatividade por departamento e cargo (Q1)

Vendas tem a maior taxa de saída entre os departamentos, mas a diferença é muito maior entre **cargos**: **Representantes de Vendas perdem 39,8%** do quadro e Técnicos de Laboratório 23,9%, enquanto cargos de gestão ficam abaixo de 7% (Figura 5). O problema está concentrado em **cargos de entrada**, e não em departamentos inteiros.

Figura 5 – Taxa de saída por departamento e por cargo



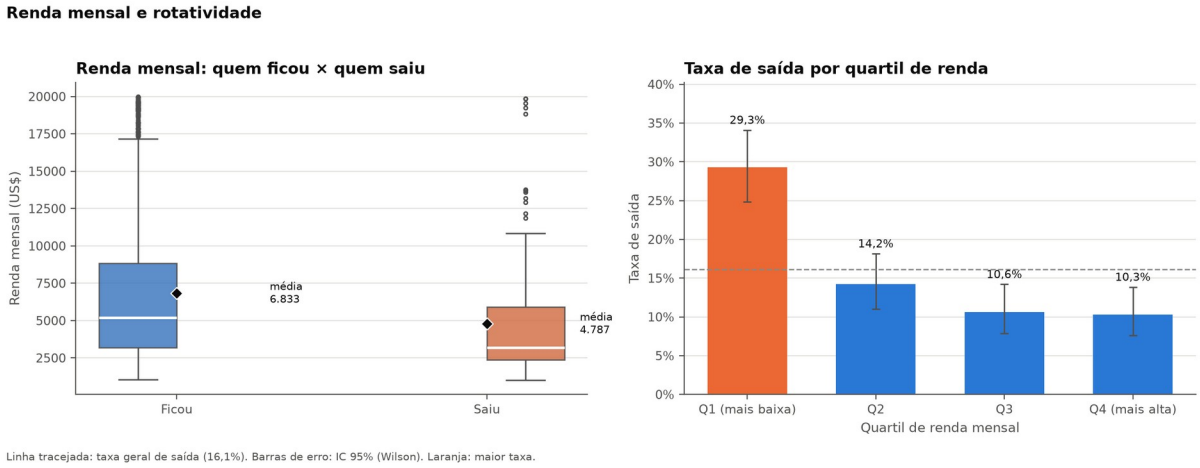
Barras de erro: IC 95% (Wilson). Linha tracejada: taxa geral. Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

3.4 Renda e rotatividade (Q2)

Quem saiu tem renda mediana de **US$ 3.202**, contra **US$ 5.204** de quem ficou. No quartil de menor renda a taxa de saída é **29,3%**, cerca de três vezes a do quartil

mais alto (10,3%) (Figura 6). Porém, **dentro do mesmo nível de cargo, a renda de quem sai e de quem fica é quase igual** (nível 1: US$ 2.437 × US$ 2.719; nível 2: US$ 5.346 × US$ 5.334), e 60% das saídas estão no nível 1. A renda baixa funciona, em boa parte, como um **marcador de início de carreira**.

Figura 6 – Renda mensal e rotatividade

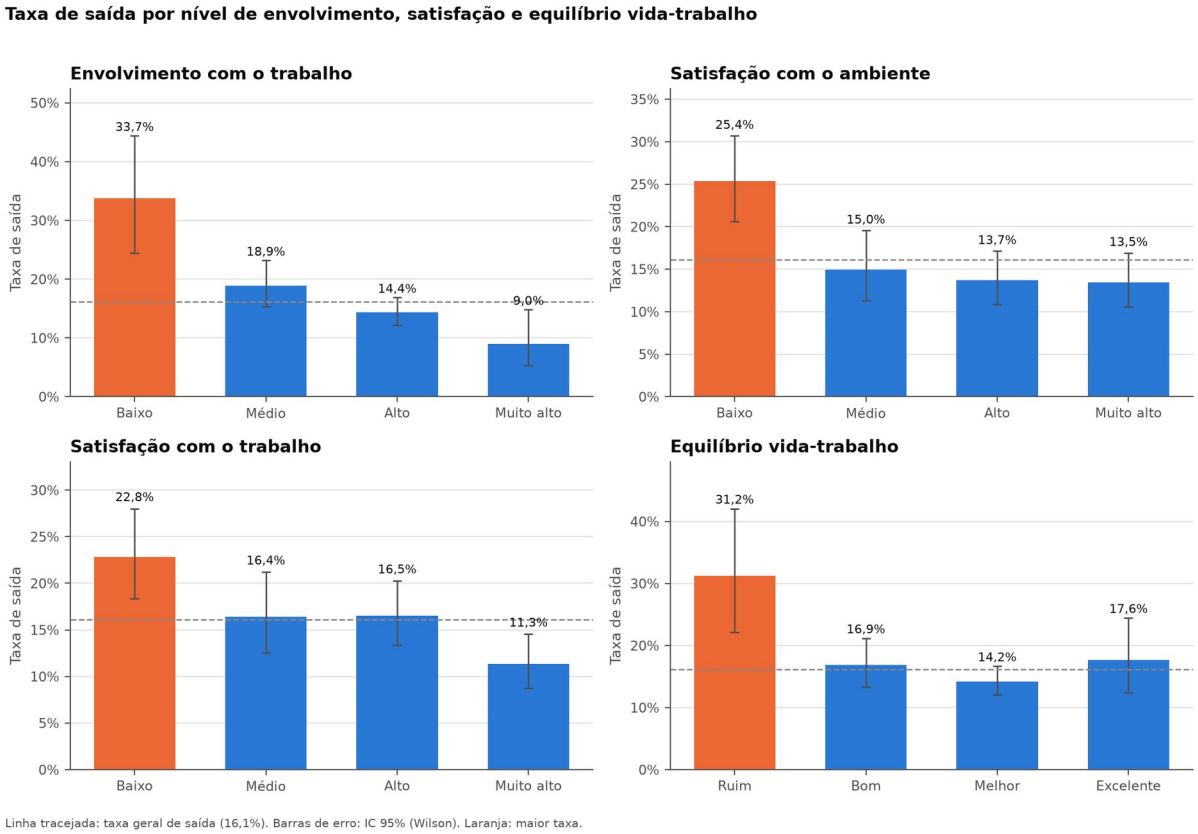


◆ = média. Barras de erro: IC 95% (Wilson). Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

3.5 Envolvimento e ambiente de trabalho (Q3)

Nas quatro escalas de percepção, **o nível mais baixo concentra o risco** (Figura 7). O envolvimento tem o gradiente mais claro: a taxa cai de **33,7%** (baixo) para **9,0%** (muito alto). Satisfação baixa com o ambiente leva a 25,4% de saída, e equilíbrio vida-trabalho "ruim" a 31,2%. Nos demais níveis, as taxas ficam próximas da média.

Figura 7 – Taxa de saída por nível de envolvimento, satisfação e equilíbrio vida-trabalho

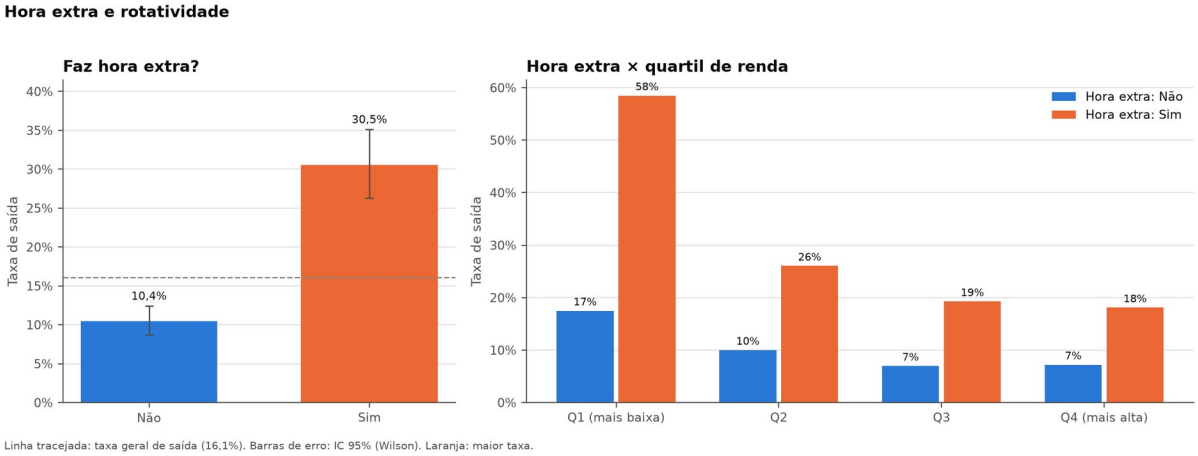


Barras de erro: IC 95% (Wilson). Laranja: maior taxa. Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

3.6 Hora extra (Q4)

Hora extra é a variável com a maior diferença entre grupos: **30,5%** de saída entre quem faz hora extra, contra **10,4%** entre quem não faz. O efeito aparece em todos os quartis de renda e é extremo no quartil mais baixo, onde mais da metade de quem faz hora extra saiu (Figura 8). **Hora extra e salário baixo somam risco.**

Figura 8 – Hora extra e rotatividade, no total e por quartil de renda

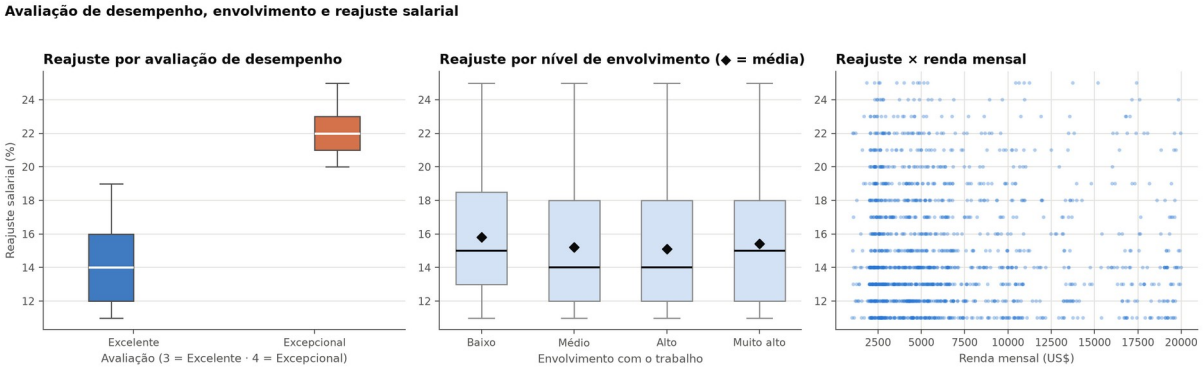


Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

3.7 Desempenho, envolvimento e reajuste (Q5)

O reajuste salarial segue uma **regra fixa atrelada à nota**: toda nota 3 recebeu entre 11% e 19%, e toda nota 4 entre 20% e 25%. O reajuste médio **não varia** com o nível de envolvimento nem com a renda (Figura 9). Além disso, a taxa de saída é praticamente igual nas duas notas (16,1% × 16,4%): **a avaliação de desempenho não diferencia quem sai de quem fica.**

Figura 9 – Avaliação de desempenho, envolvimento e reajuste salarial

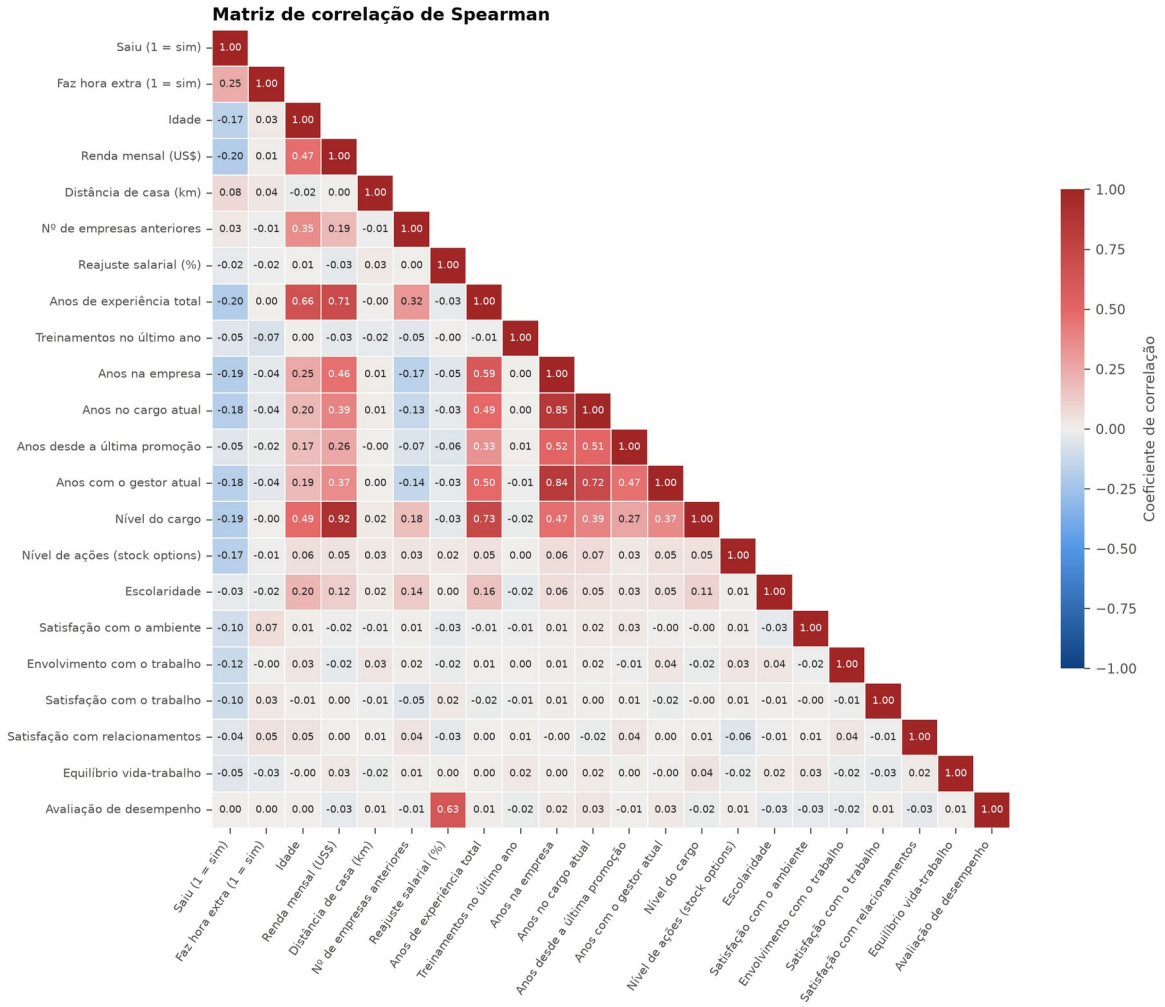


Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

3.8 Correlações e perfil de risco

Na matriz de correlação (Figura 10), a saída tem correlação positiva mais forte com **hora extra** (ρ ≈ 0,25) e negativas com **nível do cargo, renda, experiência, tempo de casa e idade** (ρ entre −0,17 e −0,20). Todas são fracas individualmente, o que indica que **a rotatividade é multifatorial**. Renda, nível do cargo e experiência são fortemente correlacionados entre si (ρ de 0,71 a 0,92), ou seja, medem a senioridade. As escalas de satisfação **não se correlacionam entre si**: são dimensões independentes, e cada uma exige ação própria.

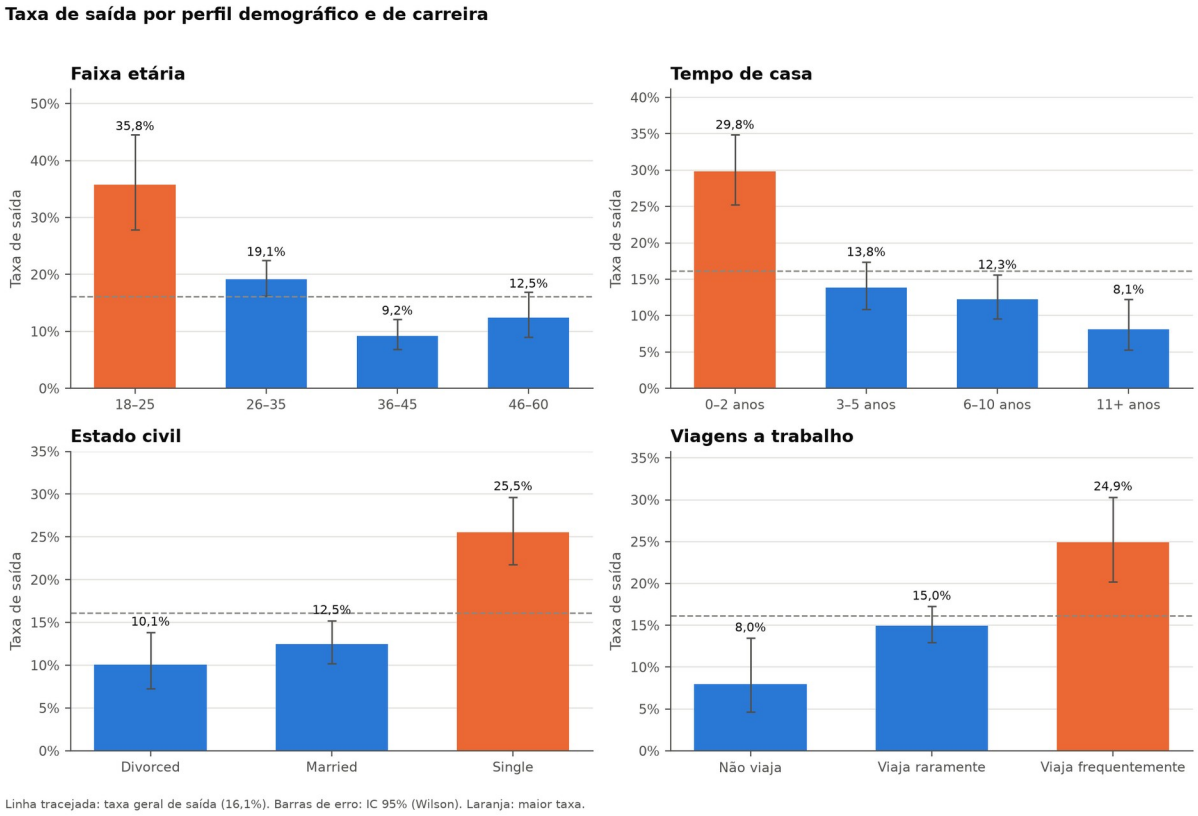
Figura 10 – Matriz de correlação de Spearman



Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

O perfil complementar (Figura 11) confirma que o risco se concentra no **início da jornada**: jovens de 18 a 25 anos, funcionários com até 2 anos de casa e solteiros têm as maiores taxas de saída. Quem viaja com frequência também sai mais.

Figura 11 – Taxa de saída por perfil demográfico e de carreira



Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

4. Análise Inferencial

Esta seção verifica se as diferenças observadas na análise descritiva são **estatisticamente significativas** ou podem ser atribuídas ao acaso. Em todos os testes, $\alpha = 0,05$: se p-valor < 0,05, rejeita-se H_0. Por se tratar de estudo observacional, os resultados indicam **associação, e não causalidade**.

4.1 Q1: Taxa de rotatividade e departamento

Intervalo de confiança. A taxa de rotatividade estimada é de 16,1%, com **IC 95% (Wilson) de 14,3% a 18,1%**: de cada 100 funcionários, entre 14 e 18 deixam a empresa. Esse valor é a linha de base para metas de retenção.

Qui-Quadrado. H_0: departamento e rotatividade são independentes; H_1: estão associados. O pressuposto de frequências esperadas ≥ 5 foi atendido (menor = 10,2). Resultado: $\chi^2(2) = 10,80$, $p = 0,0045$. **Rejeita-se H_0**: a taxa difere entre departamentos. Porém o V de Cramér = 0,086 é desprezível. O teste complementar por **cargo** também rejeita H_0 ($\chi^2 = 86,2$, $p < 0,001$), com efeito quase três vezes maior (V = 0,242). **Interpretação:** a retenção deve ser direcionada por **cargo**, e não por departamento.

4.2 Q2: Renda de quem sai × quem fica

H_0: μ(renda | saiu) = μ(renda | ficou); H_1: as médias são diferentes (bilateral). **Pressupostos:** o Shapiro-Wilk rejeitou a normalidade nos dois grupos (renda assimétrica, ver Apêndice A), mas com n = 237 e n = 1.233 o Teorema Central do Limite garante a normalidade aproximada da média amostral. O teste de Levene rejeitou a igualdade de variâncias ($p < 0,001$), então foi aplicado o **teste t de Welch**.

Resultado: $t(412,7) = -7,48$, $p < 0,001$. **Rejeita-se H_0.** Quem sai ganha em média **US$ 2.046 a menos por mês** (IC 95%: US$ 1.508 a US$ 2.583 a menos), com efeito pequeno a médio (d de Cohen = -0,44). Como verificação de robustez, o teste t sobre o **logaritmo da renda** (escala em que as variâncias são iguais e a distribuição é quase simétrica) leva à mesma conclusão ($t = -7,748$, $p < 0,001$). **Interpretação:** a diferença existe, mas reflete principalmente a concentração das saídas em cargos de entrada (Seção 3.4). O foco deve ser a atratividade da carreira inicial.

4.3 Q3: Envolvimento, ambiente, satisfação e vida-trabalho

Para cada fator: H_0: o fator e a rotatividade são independentes; H_1: estão associados. Foram aplicados quatro testes Qui-Quadrado (todas as frequências

esperadas ≥ 12,9). Como quatro testes simultâneos aumentam a chance de falso positivo, os p-valores foram ajustados pela **correção de Holm** (Tabela 6).

Tabela 6 – Testes Qui-Quadrado dos fatores de envolvimento e ambiente × rotatividade

Fator	χ^2	gl	p (Holm)	V de Cramér	Decisão
Envolvimento com o trabalho	28,49	3	< 0,001	0,139	Rejeita H_0
Satisfação com o ambiente	22,50	3	< 0,001	0,124	Rejeita H_0
Satisfação com o trabalho	17,51	3	0,0011	0,109	Rejeita H_0
Equilíbrio vida-trabalho	16,33	3	0,0011	0,105	Rejeita H_0

Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

Os quatro testes rejeitam H_0, mesmo após o ajuste. O **envolvimento** tem o maior efeito (V = 0,139): 33,7% de saída no nível baixo, contra 9,0% no muito alto. Os efeitos individuais são pequenos, mas, como as quatro dimensões são independentes entre si, **o risco se acumula** em quem tem várias dimensões no nível baixo. **Interpretação:** pesquisas de clima que identifiquem respostas "baixo" funcionam como alerta precoce de saída.

4.4 Q4: Hora extra

H_0: hora extra e rotatividade são independentes; H_1: estão associadas. Foi aplicado o **Qui-Quadrado 2×2** (com correção de Yates), complementado pelo **IC 95% da diferença de proporções** (Newcombe). Resultado: $\chi^2(1) = 87{,}56$, $p < 0{,}001$. **Rejeita-se H_0.** A taxa de saída é 30,5% com hora extra e 10,4% sem hora extra: diferença de **20,1 pontos percentuais** (IC 95%: 15,4 a 25,0 p.p.) e **risco relativo de 2,93**. É a associação mais forte do estudo (V = 0,244). **Interpretação:** se a taxa de quem faz hora extra caísse ao nível de quem não faz, seriam cerca de **84 saídas a menos** (35% do total). É um potencial, já que a relação é de associação.

4.5 Q5: Desempenho, envolvimento e reajuste

(a) Teste t (nota 4 × nota 3). H_0: o reajuste médio é igual nas duas notas. Levene rejeitou a igualdade de variâncias, então foi usado o **t de Welch** (n = 226 e 1.244; TCL aplicável). Resultado: t = 63,4, p < 0,001. **Rejeita-se H_0**: nota 4 recebe em média 21,8% contra 14,0% (diferença com IC 95% de 7,6 a 8,1 p.p.). As faixas não se sobrepõem: há uma regra fixa.

(b) ANOVA (reajuste × 4 níveis de envolvimento). H_0: as médias são iguais nos quatro níveis. Levene não rejeitou a igualdade de variâncias (p = 0,72), então foi usada a ANOVA clássica (todos os grupos com n ≥ 83). Resultado: $F(3; 1466) = 1{,}08$,

p = 0,3579. **Não se rejeita H_0** (η^2 = 0,002): o envolvimento **não é recompensado** no reajuste.

(c) Correlação (renda × reajuste). H_0: ρ = 0. Como a renda é assimétrica e com outliers, o coeficiente principal é o de **Spearman**: ρ = -0,034, p = 0,1957. **Não se rejeita H_0. Interpretação da Q5:** o reajuste depende apenas da nota, e a nota não está associada à saída. A principal ferramenta de recompensa **não atua sobre os fatores que explicam a rotatividade**.

4.6 Síntese dos resultados inferenciais

Tabela 7 – Resumo de todos os testes de hipóteses (α = 0,05)

Pergunta	Teste	Variáveis	Estatística	p-valor	Decisão	Efeito
Q1	Qui-Quadrado	Departamento × Saída	χ^2 = 10,796	0,0045	Rejeita H_0	V de Cramér = 0,086 (desprezível)
Q1	Qui-Quadrado	Cargo × Saída	χ^2 = 86,190	< 0,001	Rejeita H_0	V de Cramér = 0,242 (pequeno)
Q2	t de Welch	Renda mensal (Saiu × Ficou)	t = -7,483	< 0,001	Rejeita H_0	d de Cohen = -0,440 (pequeno)
Q2 (robustez)	t de Student	log(Renda mensal) (Saiu × Ficou)	t = -7,748	< 0,001	Rejeita H_0	d de Cohen = -0,550 (médio)
Q3	Qui-Quadrado	Envolvimento com o trabalho × Saída	χ^2 = 28,492	< 0,001 (Holm)	Rejeita H_0	V de Cramér = 0,139 (pequeno)
Q3	Qui-Quadrado	Satisfação com o ambiente × Saída	χ^2 = 22,504	< 0,001 (Holm)	Rejeita H_0	V de Cramér = 0,124 (pequeno)
Q3	Qui-Quadrado	Satisfação com o trabalho × Saída	χ^2 = 17,505	0,0011 (Holm)	Rejeita H_0	V de Cramér = 0,109 (pequeno)
Q3	Qui-Quadrado	Equilíbrio vida-trabalho × Saída	χ^2 = 16,325	0,0011 (Holm)	Rejeita H_0	V de Cramér = 0,105 (pequeno)
Q4	Qui-Quadrado (Yates)	Hora extra × Saída	χ^2 = 87,564	< 0,001	Rejeita H_0	V de Cramér = 0,244 (pequeno)
Q5	t de Welch	Reajuste salarial (Nota 4 × Nota 3)	t = 63,389	< 0,001	Rejeita H_0	d de Cohen = 3,382 (grande)
Q5	ANOVA (F de Fisher)	Reajuste salarial por Envolvimento com o trabalho (4 grupos)	F = 1,077	0,3579	Não rejeita H_0	η^2 = 0,002 (desprezível)
Q5	Correlação de Spearman	Renda mensal × Reajuste salarial	ρ = -0,034	0,1957	Não rejeita H_0	r^2 = 0,001 (desprezível)

Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

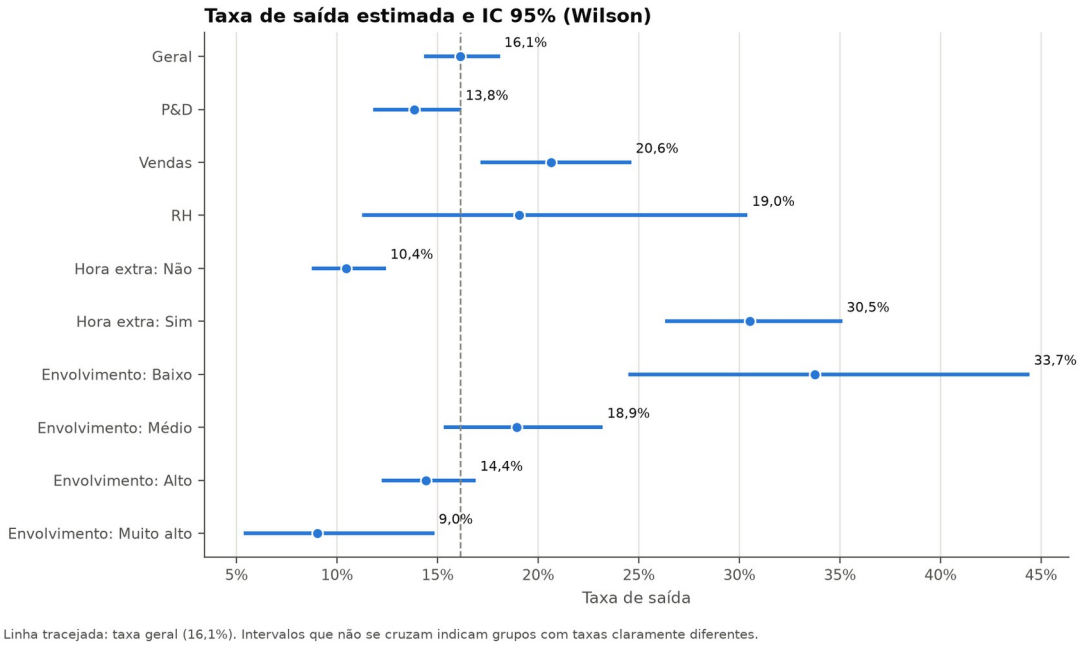
Tabela 8 – Intervalos de confiança de 95%

Pergunta	Parâmetro	Estimativa	IC 95%	Método
Q1	Taxa de rotatividade geral	16,1 %	[14,3; 18,1]	Wilson
Q1	Taxa de rotatividade — P&D	13,8 %	[11,8; 16,2]	Wilson
Q1	Taxa de rotatividade — Vendas	20,6 %	[17,1; 24,6]	Wilson
Q1	Taxa de rotatividade — RH	19,0 %	[11,2; 30,4]	Wilson
Q2	Diferença de renda média (Saiu − Ficou)	-2.045,6 US$	[-2.583,1; -1.508,2]	t de Welch
Q4	Diferença na taxa de saída (com − sem hora extra)	20,1 p.p.	[15,4; 25,0]	Newcombe
Q5	Diferença de reajuste médio (nota 4 − nota 3)	7,8 p.p.	[7,6; 8,1]	t de Welch

Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

A Figura 12 compara visualmente os intervalos das taxas de saída dos principais grupos.

Figura 12 – Taxa de saída estimada e IC 95% por grupo



Intervalos que não se cruzam indicam grupos com taxas claramente diferentes. Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

5. Recomendações Práticas

5.1 Plano de ação

As recomendações abaixo estão ordenadas por prioridade, considerando o tamanho do efeito encontrado e o grau de controle da gestão sobre cada fator. **Cada recomendação está ligada à evidência que a sustenta** (Tabela 9).

Tabela 9 – Plano de ação: recomendação, evidência, indicador e prioridade

Recomendação	Evidência	Indicador de acompanhamento	Prioridade
1. Gestão ativa de horas extras: limite mensal por pessoa, redistribuição de carga e revisão de quadro nas equipes com hora extra recorrente	Q4: $\chi^2 = 87,6$, $p < 0,001$; RR = 2,93; IC da diferença 15,4–25,0 p.p. (Fig. 8, Seção 4.4)	% do quadro com hora extra; taxa de saída de quem faz hora extra	Alta
2. Programa de retenção para cargos de entrada (Representante de Vendas, Técnico de Laboratório, nível 1): integração estruturada, mentoria, trilha de progressão e revisão do salário de entrada	Q1: cargo V = 0,24 (vs. 0,09 do departamento); Q2: t de Welch, $p < 0,001$; renda igual dentro do nível (Fig. 5, 6 e 11)	Taxa de saída nos 2 primeiros anos; taxa por cargo	Alta
3. Sistema de alerta precoce: pesquisa de clima periódica e ação individual com quem responde "baixo" em envolvimento, ambiente, satisfação ou vida-trabalho	Q3: 4 testes χ^2 com Holm, todos $p < 0,002$; envolvimento baixo = 33,7% (Fig. 7, Tabela 6)	% de respostas "baixo"; taxa de saída desse grupo	Média-alta
4. Revisão da política de reconhecimento: incluir envolvimento e engajamento nos critérios de reajuste e calibrar a avaliação de desempenho (hoje só notas 3 e 4)	Q5: t (nota → reajuste) $p < 0,001$; ANOVA $p = 0,3579$; correlação $p = 0,1957$; saída igual nas duas notas (Fig. 9)	Distribuição das notas; reajuste médio por nível de envolvimento	Média

Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

Recomendação 1 (prioridade alta). Hora extra é o fator de maior efeito e o que está **sob controle mais direto** da gestão. Se a taxa de saída de quem faz hora extra caísse ao nível de quem não faz, o potencial seria de cerca de **84 saídas a menos por ciclo**, o que levaria a taxa geral de 16,1% para cerca de 10,4%.

Recomendação 2 (prioridade alta). As saídas se concentram em cargos de entrada, em funcionários jovens e com pouco tempo de casa. Como, no mesmo nível, quem sai não ganha menos que os pares, o problema é a **atratividade da carreira inicial** como um todo (salário de entrada, perspectiva de crescimento e integração), e não reajustes individuais.

Recomendação 3 (prioridade média-alta). Envolvimento, ambiente, satisfação e equilíbrio vida-trabalho são dimensões **independentes**, e o risco se concentra no nível mais baixo de cada uma. Um painel que cruze as respostas da pesquisa de clima permite **agir antes do pedido de demissão**.

Recomendação 4 (prioridade média). Hoje o reajuste depende só da nota de desempenho, e a nota não diferencia quem sai. Incluir o envolvimento nos critérios de reconhecimento alinha a política de remuneração aos fatores que de fato estão associados à permanência.

5.2 Limitações e próximos passos

- Os dados são **fictícios** (simulados pela IBM): as recomendações demonstram o método e devem ser validadas com dados reais da organização;
- O estudo é **observacional** e de corte transversal: os testes indicam **associação, não causalidade**;
- Os fatores estão interligados (por exemplo, renda, nível e experiência). Um próximo passo é um **modelo multivariado** (regressão logística) para estimar o efeito de cada fator controlando os demais;
- A avaliação de desempenho tem só duas notas, o que limita a análise da Q5.

6. Referências e Apêndices

6.1 Referências

IBM. **IBM HR Analytics Employee Attrition & Performance**. Kaggle, 2017. Disponível em: https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset/data. Acesso em: out. 2026.

COHEN, J. **Statistical power analysis for the behavioral sciences**. 2. ed. Hillsdale: Lawrence Erlbaum, 1988.

HOLM, S. A simple sequentially rejective multiple test procedure. **Scandinavian Journal of Statistics**, v. 6, n. 2, p. 65-70, 1979.

NEWCOMBE, R. G. Interval estimation for the difference between independent proportions: comparison of eleven methods. **Statistics in Medicine**, v. 17, n. 8, p. 873-890, 1998.

WELCH, B. L. The generalization of "Student's" problem when several different population variances are involved. **Biometrika**, v. 34, n. 1-2, p. 28-35, 1947.

WILSON, E. B. Probable inference, the law of succession, and statistical inference. **Journal of the American Statistical Association**, v. 22, n. 158, p. 209-212, 1927.

McKINNEY, W. Data structures for statistical computing in Python. In: **Proceedings of the 9th Python in Science Conference**, 2010. p. 56-61.

VIRTANEN, P. et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. **Nature Methods**, v. 17, p. 261-272, 2020.

SEABOLD, S.; PERKTOLD, J. statsmodels: econometric and statistical modeling with Python. In: **Proceedings of the 9th Python in Science Conference**, 2010.

HUNTER, J. D. Matplotlib: a 2D graphics environment. **Computing in Science & Engineering**, v. 9, n. 3, p. 90-95, 2007.

WASKOM, M. L. seaborn: statistical data visualization. **Journal of Open Source Software**, v. 6, n. 60, p. 3021, 2021.

6.2 Código-fonte e reprodutibilidade

Repositório do projeto: **https://github.com/josefideles/sisb110-ibm-hr-analytics**.

Para reproduzir a análise: criar o ambiente virtual, instalar *requirements.txt* e executar *python run_all.py*. Os notebooks *01_contexto_e_limpeza*, *02_analise_descritiva* e *03_analise_inferencial* documentam cada decisão.

Apêndice A – Verificação dos pressupostos

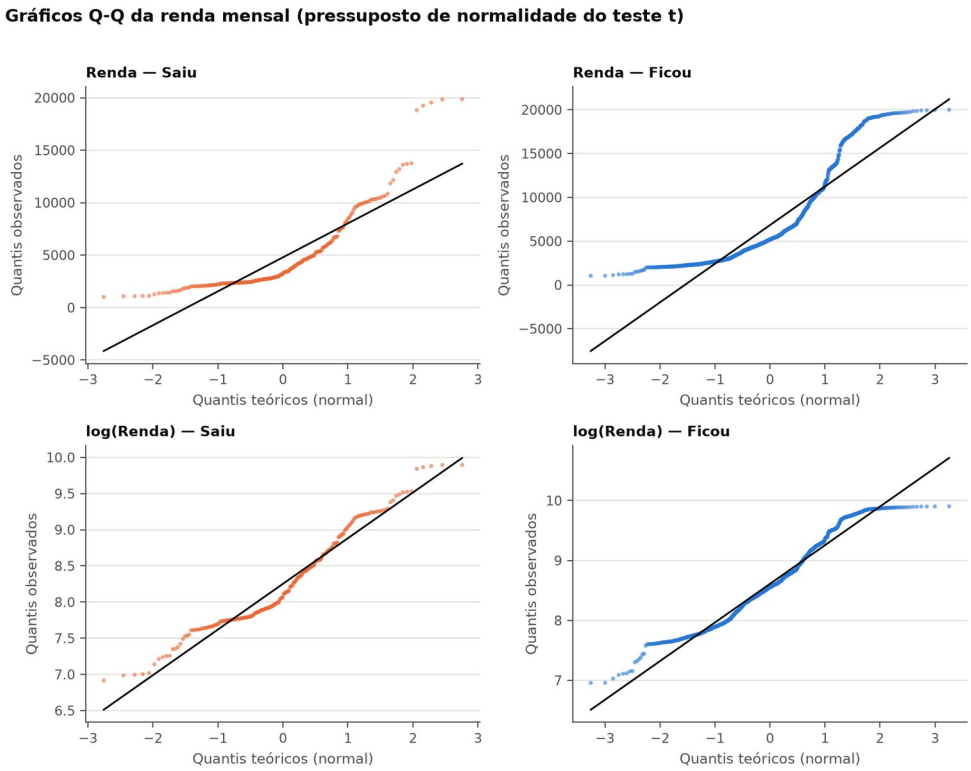
Tabela 10 – Verificação dos pressupostos dos testes

Teste	Pressuposto	Verificação	Resultado / tratamento
Todos	Independência das observações	1 linha = 1 funcionário; 0 duplicatas	Atendido
Qui-Quadrado (Q1, Q3, Q4)	Frequências esperadas ≥ 5	Menor esperada = 10,2	Atendido

Teste	Pressuposto	Verificação	Resultado / tratamento
Teste t (Q2)	Normalidade (Shapiro-Wilk)	Rejeitada (assimetria 1,9 e 1,3)	Contornado pelo TCL (n = 237 e 1.233) e pela escala log
Teste t (Q2)	Igualdade de variâncias (Levene)	Rejeitada (p < 0,001)	Usado t de Welch
Teste t (Q5a)	Igualdade de variâncias (Levene)	Rejeitada (p < 0,001)	Usado t de Welch
ANOVA (Q5b)	Igualdade de variâncias (Levene)	p = 0,72	Atendido: ANOVA clássica
ANOVA (Q5b)	Normalidade dos resíduos	Rejeitada	Contornado pelo TCL (n ≥ 83 por grupo)
Correlação (Q5c)	Linearidade / outliers	Renda assimétrica, sem padrão linear	Usado Spearman

Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

Figura 13 – Gráficos Q-Q da renda mensal (escala original e logarítmica)



Pontos próximos da reta indicam distribuição aproximadamente normal. Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).

Apêndice B – Dicionário de dados resumido

Tabela 11 – Variáveis analisadas, descrição e tipo estatístico

Variável (original)	Descrição	Tipo
Age	Idade	Quantitativa contínua
MonthlyIncome	Renda mensal (US$)	Quantitativa contínua
DistanceFromHome	Distância de casa (km)	Quantitativa discreta
NumCompaniesWorked	Nº de empresas anteriores	Quantitativa discreta
PercentSalaryHike	Reajuste salarial (%)	Quantitativa discreta
TotalWorkingYears	Anos de experiência total	Quantitativa discreta
TrainingTimesLastYear	Treinamentos no último ano	Quantitativa discreta
YearsAtCompany	Anos na empresa	Quantitativa discreta
YearsInCurrentRole	Anos no cargo atual	Quantitativa discreta
YearsSinceLastPromotion	Anos desde a última promoção	Quantitativa discreta
YearsWithCurrManager	Anos com o gestor atual	Quantitativa discreta

Variável (original)	Descrição	Tipo
Attrition	Rotatividade (saiu?)	Qualitativa nominal
Department	Departamento	Qualitativa nominal
JobRole	Cargo	Qualitativa nominal
EducationField	Área de formação	Qualitativa nominal
Gender	Gênero	Qualitativa nominal
MaritalStatus	Estado civil	Qualitativa nominal
OverTime	Hora extra	Qualitativa nominal
BusinessTravel	Viagens a trabalho	Qualitativa ordinal
Education	Escolaridade	Qualitativa ordinal
EnvironmentSatisfaction	Satisfação com o ambiente	Qualitativa ordinal
JobInvolvement	Envolvimento com o trabalho	Qualitativa ordinal
JobLevel	Nível do cargo	Qualitativa ordinal
JobSatisfaction	Satisfação com o trabalho	Qualitativa ordinal
PerformanceRating	Avaliação de desempenho	Qualitativa ordinal
RelationshipSatisfaction	Satisfação com relacionamentos	Qualitativa ordinal
StockOptionLevel	Nível de ações (stock options)	Qualitativa ordinal
WorkLifeBalance	Equilíbrio vida-trabalho	Qualitativa ordinal

Fonte: elaboração própria a partir de IBM HR Analytics (Kaggle, 2017).